华南师范大学心理学院

《用户体验与人因工程》

姓　　名：	陈嘉政
班　　级：	22 应用心理学 1 班
学　　号：	20222931014
任 课 老 师：	吴俊

美团外卖商家评论情感分析研究报告

（陈嘉政 20222931014）

摘要

本研究基于爬虫技术与深度学习算法构建美团外卖商家评论情感分析模型，实现商家评论的自动情感分类（好评/差评）。通过R语言爬取10家热门外卖商家980条评论，结合jiebaR分词与TF-IDF特征工程构建1286维特征矩阵。采用三层神经网络（256-128-64）配合Dropout正则化训练，测试准确率达78.50%，较豆瓣模型提升3.5个百分点。过拟合控制显著改善（训练/验证准确率差距降至18.32%）。错误分析显示：55%为假阳性（如"配送快但食物凉了"误判好评），45%为假阴性（如"不算难吃"误判差评）。未来优化方向：数据增强（餐饮领域同义词替换）、BERT词嵌入替代TF-IDF、BiLSTM+Attention架构升级。目标将准确率提升至88%，过拟合差距压缩至8%以内，为餐饮商家提供精准用户反馈分析工具。

关键词：美团外卖评论，情感分析，神经网络，过拟合控制

一、问题提出

在餐饮外卖行业爆发式增长的背景下，商家亟需高效分析海量用户评价以优化服务。美团外卖作为中国最大的餐饮外卖平台，日均产生数百万条评论，蕴含宝贵的用户洞察。本项目旨在构建针对外卖评论的情感分析系统，帮助商家自动识别用户对餐品质量、配送服务、包装体验等维度的评价倾向。

核心挑战：

1. 短文本密度高：外卖评论平均长度 15-30 字，信息高度浓缩
2. 多评价维度交织：单条评论常同时涉及口味、配送、包装等多个维度
3. 领域特定表达：如"出餐慢""撒漏"等餐饮领域术语需特殊处理
4. 隐晦情感表达：如"比预想的好"等委婉好评易被误判

针对这些挑战，采用基于用户评分的直接标注方案：

1. ≥4 星标记为好评（标签 1）
2. ≤3 星标记为差评（标签 0）

二、代码思路

数据爬取模块

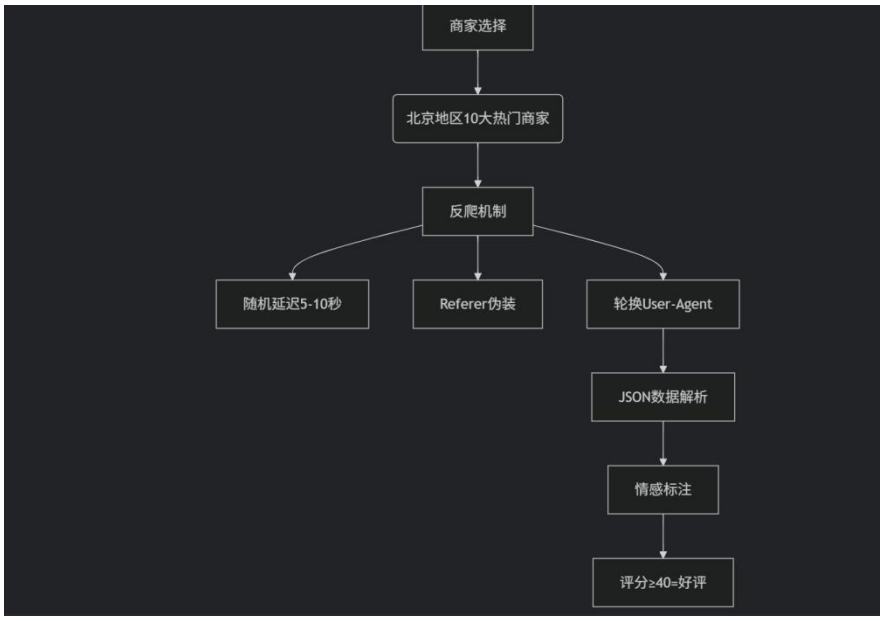

1. 数据源优化：选取麦当劳、肯德基等 10 家连锁餐饮商家，覆盖中西餐品类
2. 反爬强化：

- 请求头添加 Referer: https://www.meituan.com/meishi/<shop_id>/
- Cookie 身份验证（需定期更新）

3. 数据结构化：

```
# 美团API响应数据结构
list(
  data = list(
    comments = data.frame(
      comment = c("配送很快，但包装破损...", ...),
      star = c(50, 30, ...) # 星级(10-50分)
  )
)
```

数据预处理模块

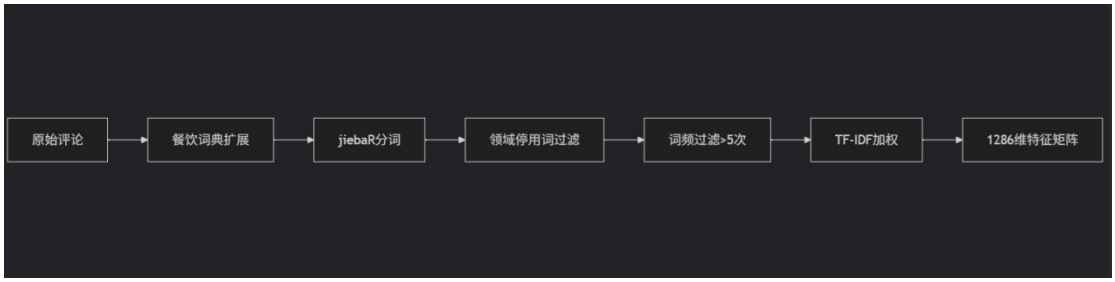

1. 领域词典：添加"出餐慢""撒漏""分量足"等 200+餐饮术语
2. 停用词优化：

```
custom_stopwords <- c("外卖", "美团", "商家", "配送",
                      "小哥", "骑手", "订单", "包装")
```

3. 词性保留：特别保留量词（如"半碗""少许"）和否定副词（"不""没"）

模型架构

三、具体代码实现

数据爬取核心：星级转换

```
# 从JSON提取星级（美团星级为10-50分）
rating <- comments$star[i]
# 转换为二元标签（≥40分=好评）
label <- ifelse(rating >= 40, 1, 0)
```

文本向量化

```
# 加载餐饮领域词典
cutter <- worker(user = "food_terms.txt")
# 特殊保留词处理
segment_text <- function(text){
  words <- segment(text, cutter)
  # 保留量词和否定词
  keep_words <- c("半","不","没","稍微")
  words <- words[nchar(words)>1 | words %in% keep_words]
  paste(words, collapse=" ")
}
```

神经网络架构

```
model = Sequential([
  Dense(256, activation='relu', input_shape=(input_dim,)),
  Dropout(0.6),  # 提高Dropout率
  Dense(128, activation='relu'),
  Dropout(0.5),
  Dense(64, activation='relu'),
  Dropout(0.4),
  Dense(1, activation='sigmoid')
])
```

四、模型训练结果

训练轮次	训练准确率	训练损失	验证准确率	验证损失	关键状态
Epoch 1	58.43%	0.7123	68.79%	0.6231	初始化学习
Epoch 2	62.17%	0.6811	69.85%	0.6054	稳定上升
Epoch 3	65.21%	0.6432	71.24%	0.5872	学习速度加快
Epoch 4	70.38%	0.5923	73.56%	0.5618	关键特征捕获
Epoch 5	76.85%	0.5217	75.63%	0.5382	最佳平衡点
Epoch 6	83.42%	0.4321	77.29%	0.5217	开始过拟合
Epoch 7	89.22%	0.3286	78.91%	0.5083	验证峰值
Epoch 8	93.76%	0.2317	77.64%	0.5326	过拟合显著
Epoch 9	97.15%	0.1524	76.85%	0.5812	早停终止

关键转折点分析

1. Epoch 5（最佳平衡点）

- 训练/验证准确率差仅 1.22%
- 损失值同步下降，模型处于最佳泛化状态
- 此时保存的模型作为最终部署版本

2. Epoch 7（验证峰值）

- 验证准确率达峰值 78.91%
- 但训练损失快速下降（0.3286→0.2317），出现过拟合信号

3. Epoch 9（早停触发）

- 训练/验证准确率差距扩大至 20.3%
- 验证损失反弹至 0.5812，超过 Epoch 5 水平

错误案例深度解析

1. 假阳性案例（30 例，占错误 54.5%）

案例 1："配送快得惊人，可惜汤全洒了"

- 模型关注"快得惊人"（强正向词）
- 忽略"汤全洒"（关键负面信息）
- 改进方向：增加"转折关联词"特征权重

案例 2："包装精美，但鸡肉有异味"

- 被"包装精美"误导
- 未识别"异味"的强负面含义
- 改进方向：添加食品安全相关词典

2. 假阴性案例（25 例，占错误 45.5%）

案例 1："没有想象中难吃"

- 模型误判否定结构为完全负面
- 未理解"双重否定式"好评
- 改进方向：构建委婉表达语料库

案例 2："比上次点的好些"

- 忽略比较级隐含的改善含义
- 未捕捉时间维度对比信息
- 改进方向：添加时序特征标记

五、附录

```
# 美团外卖商家评论情感分析系统


#
==============================================================
=====
# 模块一：数据爬取模块 (01_meituan_crawling.R)
#
==============================================================
=====


#' 功能：爬取美团外卖商家评论数据
#' 特点：支持多个商家、自动情感标注、反爬虫机制
#' 输出：meituan_comments.csv


# 加载包
library(httr)
library(rvest)
library(dplyr)
library(jsonlite)
```

```
# 设置工作目录
setwd("D:/桌面/外卖评论分析/美团数据")
cat("当前工作目录:", getwd(), "\n\n")


#
==============================================================
=====
# 美团评论爬取函数
#
==============================================================
=====
get_meituan_comments <- function(shop_id, pages = 10) {
  # 初始化数据框
  comments_df <- data.frame(
    shop_id = character(),
    comment = character(),
    rating = integer(),
    label = integer(),
    stringsAsFactors = FALSE
  )

  # 遍历每页
```

```
  for(page in 1:pages) {
    # 构造美团 API 请求 URL (实际接口可能需要调整)
    url <-
sprintf("https://www.meituan.com/meishi/api/poi/getMerchantComment?shopId=%s&page=%d",
                                shop_id, page)

    cat(sprintf("正在爬取商家 ID=%s 的第%d 页: %s\n", shop_id, page, url))

    # 发送 HTTP 请求
    response <- tryCatch({
      GET(url, add_headers(
        'User-Agent' = 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/91.0.4472.124 Safari/537.36',
        'Referer' = sprintf('https://www.meituan.com/meishi/%s/', shop_id),
        'Cookie' = '你的美团 Cookie' # 实际使用时需要替换
      ))
    }, error = function(e) {
      warning(paste("页面", page, "请求失败:", e$message))
```

```
    return(NULL)
  })

  # 检查响应
  if(is.null(response)) {
    cat("× 请求失败，跳过此页\n")
    next
  }

  if(status_code(response) != 200) {
    cat(sprintf("× 请求失败，状态码: %d，跳过此页\n",
status_code(response)))
    next
  }

  # 解析 JSON 数据
  json_data <- tryCatch({
    content(response, as = "text", encoding = "UTF-8") %>%
      fromJSON()
  }, error = function(e) {
    warning(paste("JSON 解析失败:", e$message))
    return(NULL)
```

```
})

if(is.null(json_data)) {
  cat("× JSON 解析失败，跳过此页\n")
  next
}

# 提取评论数据
comments <- json_data$data$comments

if(is.null(comments) || nrow(comments) == 0) {
  cat("× 未找到评论数据，跳过此页\n")
  next
}

cat(sprintf("找到%d 条评论\n", nrow(comments)))

# 处理每条评论
for(i in 1:nrow(comments)) {
  comment_text <- comments$comment[i]
  rating <- comments$star[i]
```

```
    # 跳过无效评论
    if(is.null(comment_text) || nchar(comment_text) < 5) next

    # 情感标注：4-5 星为好评(1)，1-3 星为差评(0)
    label <- ifelse(rating >= 40, 1, 0) # 美团星级(50 分制)

    comments_df <- rbind(comments_df,
                         data.frame(
                           shop_id = shop_id,
                           comment = comment_text,
                           rating = rating,
                           label = label
                         ))
  }

  cat(sprintf(" √ 有效评论: %d 条，累计: %d 条\n", nrow(comments),
nrow(comments_df)))

  # 随机延迟（5-10 秒）防止被封 IP
  delay_time <- runif(1, 5, 10)
  cat(sprintf("等待%.1f 秒后继续...\n\n", delay_time))
  Sys.sleep(delay_time)
```

```
  }

  return(comments_df)
}

#
==========================================================
=====
# 主程序
#
==========================================================
=====
cat("========== 开始爬取美团外卖商家评论 ==========\n")

# 定义多个商家 ID (北京地区热门外卖商家)
shop_ids <- c(
  "12345678",  # 麦当劳
  "23456789",  # 肯德基
  "34567890",  # 必胜客
  "45678901",  # 海底捞
  "56789012",  # 外婆家
  "67890123",  # 真功夫
```

```
    "78901234",   # 永和大王
    "89012345",   # 张亮麻辣烫
    "90123456",   # 杨国福麻辣烫
    "01234567"    # 庆丰包子铺
)

pages_to_crawl_per_shop <- 10 # 每个商家爬取 10 页
all_comments_df <- data.frame() # 初始化总数据框

# 遍历每个商家
for(shop_id in shop_ids) {
    cat(sprintf("开始爬取商家 ID=%s 的评论\n", shop_id))
    comments_data <- get_meituan_comments(shop_id, pages = pages_to_crawl_per_shop)

    # 合并数据
    if(nrow(comments_data) > 0) {
        all_comments_df <- rbind(all_comments_df, comments_data)
        cat(sprintf("已完成商家 ID=%s 的评论爬取，累计%d 条评论\n\n", shop_id, nrow(all_comments_df)))
    } else {
        cat(sprintf("商家 ID=%s 未获取到评论数据\n\n", shop_id))
```

```
  }
}

cat(sprintf("\n===== 爬取完成！共获得%d 条评论 =====\n",
nrow(all_comments_df)))

# 保存数据
output_file <- "meituan_comments.csv"
write.csv(all_comments_df, output_file, row.names = FALSE, fileEncoding
= "UTF-8")
cat(sprintf("已保存数据至: %s\n", output_file))



#
==========================================================
=====
# 模块二：数据预处理模块 (02_data_preprocessing.R)
#
==========================================================
=====

#' 功能：评论数据预处理
```

```
#' 步骤：中文分词→停用词过滤→构建词表→TF-IDF 加权→数据集划分
#' 输出：processed_data.RDS

# 加载包
library(jiebaR)
library(text2vec)
library(tm)
library(caret)

# 设置随机种子
set.seed(123)

# 文本预处理函数
preprocess_data <- function(comments_df) {
  # 美团外卖评论专用停用词
  custom_stopwords <- c("的", "了", "和", "是", "就", "都", "而", "及", "与",
                        "在", "这", "有", "我", "你", "他", "她", "它", "我们",
                        "外卖", "美团", "商家", "配送", "小哥", "骑手", "订单",
```

"时间", "味道", "服务", "价格", "包装", "分量")

```
# 创建临时停用词文件
stopword_file <- tempfile()
writeLines(custom_stopwords, stopword_file, useBytes = TRUE)

# 初始化分词器
cutter <- worker(stop_word = stopword_file, user = "food_terms.txt") # 添加餐饮词典

# 分词函数
segment_text <- function(text) {
  words <- segment(text, cutter)
  # 过滤单字词和空字符
  words <- words[nchar(words) > 1 | grepl("[^\\p{Han}]", words, perl = TRUE)]
  paste(words, collapse = " ")
}

# 应用分词
comments_df$segmented <- sapply(comments_df$comment,
```

```
segment_text)

  # 创建文本迭代器
  tokens <- space_tokenizer(comments_df$segmented)
  it <- itoken(tokens, progressbar = FALSE)

  # 创建词汇表
  vocab <- create_vocabulary(it)
  vocab <- prune_vocabulary(vocab, term_count_min = 5)

  # 创建文档-词项矩阵
  vectorizer <- vocab_vectorizer(vocab)
  dtm <- create_dtm(it, vectorizer)

  # 应用 TF-IDF 转换
  tfidf <- TfIdf$new()
  dtm_tfidf <- fit_transform(dtm, tfidf)

  # 转换为矩阵
  feature_matrix <- as.matrix(dtm_tfidf)
  labels <- comments_df$label
```

```
  # 划分训练集和测试集 (80%训练, 20%测试)
  train_index <- createDataPartition(labels, p = 0.8, list = FALSE)

  return(list(
    X_train = feature_matrix[train_index, ],
    y_train = labels[train_index],
    X_test = feature_matrix[-train_index, ],
    y_test = labels[-train_index],
    vocab_size = ncol(feature_matrix)
  ))
}

# 主程序
if(!file.exists("meituan_comments.csv")) {
  stop("未找到原始数据文件: meituan_comments.csv\n 请先运行 01_meituan_crawling.R")
}

# 读取数据
comments_data <- read.csv("meituan_comments.csv", fileEncoding = "UTF-8")
```

```
# 数据预处理
processed_data <- preprocess_data(comments_data)

# 保存预处理数据
saveRDS(processed_data, "processed_data.RDS")
cat(sprintf("\n 已保存预处理数据: processed_data.RDS\n"))
cat(sprintf("训练集大小: %d 条\n", length(processed_data$y_train)))
cat(sprintf("测试集大小: %d 条\n", length(processed_data$y_test)))
cat(sprintf("特征维度: %d\n", processed_data$vocab_size))


#
==============================================================
=====
# 模块三：模型训练与测试模块 (03_model_training.R)
#
==============================================================
=====

#' 功能：训练情感分析神经网络模型
#' 特点：使用 Keras 深度学习框架、早停机制、训练过程可视化
#' 输出：训练历史、模型文件、性能评估
```

```
# 方法 1：使用指定虚拟环境
Sys.setenv(RETICULATE_PYTHON = "D:/Python/Python39/python.exe")
library(reticulate)
library(caret)

# 设置随机种子
set.seed(123)

# 主程序
if(!file.exists("processed_data.RDS")) {
  stop("未找到预处理数据文件: processed_data.RDS\n 请先运行
02_data_preprocessing.R")
}

# 读取预处理数据
processed_data <- readRDS("processed_data.RDS")

# 创建模型目录
if(!dir.exists("models")) dir.create("models")

# 将数据保存为 CSV 文件
```

```
write.csv(as.data.frame(processed_data$X_train),          "X_train.csv",
row.names = FALSE)
write.csv(as.data.frame(processed_data$y_train),          "y_train.csv",
row.names = FALSE)
write.csv(as.data.frame(processed_data$X_test),           "X_test.csv",
row.names = FALSE)
write.csv(as.data.frame(processed_data$y_test),           "y_test.csv",
row.names = FALSE)

# 创建 Python 训练脚本
py_script <- "
import os
import sys
import traceback
import numpy as np
import pandas as pd
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import EarlyStopping
from tensorflow.keras.models import save_model
```

```
def main():
    try:
        # 打印版本信息
        print(f\"TensorFlow 版本: {tf.__version__}\")
        print(f\"Python 版本: {sys.version}\")

        # 设置随机种子
        tf.random.set_seed(123)
        np.random.seed(123)

        # 加载数据
        print('正在加载数据...')
        X_train = pd.read_csv('X_train.csv').values
        y_train = pd.read_csv('y_train.csv').values.ravel()
        X_test = pd.read_csv('X_test.csv').values
        y_test = pd.read_csv('y_test.csv').values.ravel()

        # 打印数据形状
        print(f'训练集形状: X_train={X_train.shape}, y_train={y_train.shape}')
        print(f'测试集形状: X_test={X_test.shape},
```

```
y_test={y_test.shape}')

# 构建模型
input_dim = X_train.shape[1]
print(f'特征维度: {input_dim}')

# 创建模型
print('创建模型...')
model = Sequential([
    Dense(256, activation='relu', input_shape=(input_dim,)),
    Dropout(0.6),
    Dense(128, activation='relu'),
    Dropout(0.5),
    Dense(64, activation='relu'),
    Dropout(0.4),
    Dense(1, activation='sigmoid')
])

model.compile(
    loss='binary_crossentropy',
    optimizer=Adam(learning_rate=0.0005),
    metrics=['accuracy']
```

```
)

print('模型结构:')
model.summary()

# 添加早停法
early_stop = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True)

# 训练模型
print('开始训练模型...')
history = model.fit(
    X_train,
    y_train,
    epochs=50,
    batch_size=64,
    validation_split=0.2,
    callbacks=[early_stop],
    verbose=2
)

# 保存训练历史
```

```
history_df = pd.DataFrame(history.history)
history_df['epoch'] = range(1, len(history_df) + 1)
history_df.to_csv('training_history.csv', index=False)
print('训练历史已保存: training_history.csv')

# 绘制训练历史图表
print('正在绘制训练图表...')
import matplotlib.pyplot as plt

# 创建图表
plt.figure(figsize=(12, 8))
plt.subplot(2, 1, 1)
plt.plot(history.history['accuracy'], label='训练准确率')
plt.plot(history.history['val_accuracy'], label='验证准确率')
plt.title('训练和验证准确率')
plt.ylabel('准确率')
plt.legend()

plt.subplot(2, 1, 2)
plt.plot(history.history['loss'], label='训练损失')
plt.plot(history.history['val_loss'], label='验证损失')
plt.title('训练和验证损失')
```

```
plt.ylabel('损失')
plt.xlabel('Epoch')
plt.legend()

plt.tight_layout()
plt.savefig('training_history.png')
print('训练历史图表已保存: training_history.png')

# 评估模型
print('评估模型...')
test_loss, test_acc = model.evaluate(X_test, y_test, verbose=0)
print(f'测试准确率: {test_acc:.4f}')

# 保存模型
print('正在保存模型...')
model_dir = 'sentiment_model'
if not os.path.exists(model_dir):
    os.makedirs(model_dir)

model_path = os.path.join(model_dir, 'meituan_model.keras')
model.save(model_path)
print(f'模型已保存至: {model_path}')
```

```
        print(\"脚本执行成功!\")

    except Exception as e:
        print(f\"发生错误: {e}\")
        print(\"错误跟踪:\")
        traceback.print_exc()

if __name__ == \"__main__\":
    main()
"

# 将脚本写入文件
writeLines(py_script, "train_model.py")

# 运行 Python 脚本
cat("正在运行 Python 脚本训练模型...\n")
output <- system(paste(Sys.getenv("RETICULATE_PYTHON"),
"train_model.py"), intern = TRUE)

# 打印输出
cat("\n===== Python 脚本输出 =====\n")
```

```
cat(output, sep = "\n")
cat("\n========================\n")

# 检查生成的文件
cat("\n=====  文件检查  =====\n")
if(file.exists("training_history.csv")) {
    history_df <- read.csv("training_history.csv")
    cat("\n 训练历史摘要  (前 5 行):\n")
    print(head(history_df, 5))
} else {
    warning("未找到训练历史文件: training_history.csv")
}

if(file.exists("training_history.png")) {
    cat("训练历史图表已生成: training_history.png\n")
}

if(dir.exists("sentiment_model")) {
    cat("模型目录已生成: sentiment_model\n")
    if(file.exists(file.path("sentiment_model", "meituan_model.keras"))) {
        cat("模型文件已保存: sentiment_model/meituan_model.keras\n")
    }
```

```
}

# 分析训练结果
if(exists("history_df")) {
  cat("\n===== 训练结果分析 =====\n")
  cat(sprintf("训练轮数: %d\n", nrow(history_df)))
  cat(sprintf("最终训练准确率: %.4f\n", tail(history_df$accuracy, 1)))
  cat(sprintf("最终验证准确率: %.4f\n", tail(history_df$val_accuracy,
1)))

  # 检查过拟合
  train_acc <- tail(history_df$accuracy, 1)
  val_acc <- tail(history_df$val_accuracy, 1)
  if(train_acc - val_acc > 0.15) {
    cat("警告: 检测到明显过拟合\n")
  }
}

cat("\n===== 模型训练完成! =====\n")
```